BÁO CÁO CHI PHÍ ASR

Cloudflare hay Vertex AI cho 1 người dùng?

Giả định sử dụng nhận dạng giọng nói 10 phút mỗi ngày

Khối lượng: 10 phút/ngày x 30 ngày = 300 phút/tháng = 5 giờ audio
Vertex tham chiếu: Custom Whisper endpoint, n1-standard-4 + NVIDIA Tesla T4, us-central1
Ngày giá: 21/08/2026; quy đổi 26.000 VND/USD; chưa gồm thuế

KẾT LUẬN: Chọn Cloudflare. Với 10 phút/ngày, Workers AI chỉ dùng khoảng 466 Neurons/ngày, thấp hơn quota miễn phí 10.000 Neurons/ngày. Chi phí Cloudflare có thể là 0 USD/tháng trên Free plan hoặc 5 USD/tháng nếu chủ động dùng Workers Paid. Vertex AI không kinh tế cho một người dùng.

Kết quả tính nhanh

Phương án	Chi phí tháng	Quy đổi VND	Đánh giá
Cloudflare Free	$0	0đ	Tốt nhất; nằm trong quota AI miễn phí
Cloudflare Paid	$5,00	130.000đ	Production nhỏ; ASR vẫn trong quota miễn phí
Vertex scale-to-zero	Khoảng $18,63+	Khoảng 484.000đ+	Có cold start; ước tính một giờ hoạt động/ngày
Vertex luôn chạy	$453,33	11,79 triệu	Độ trễ tốt hơn nhưng quá đắt cho 1 user

Giá trị suy theo đơn giá Cloudflare là 300 x 0,00051 = 0,153 USD/tháng (khoảng 3.978đ), nhưng khoản này không bị tính tiền khi mỗi ngày vẫn dưới quota Neurons miễn phí.

Quyết định thực tế

- **POC hoặc một người dùng:** Cloudflare Free, tổng hạ tầng ASR có thể bằng 0.
- **Production nhỏ:** Cloudflare Paid 5 USD/tháng nếu cần hạn mức Workers cao hơn và tránh request bị chặn khi vượt Free plan.
- **Vertex AI:** chỉ dùng khi cần model tùy biến, IAM/VPC của GCP hoặc yêu cầu dữ liệu đặc thù; không chọn để tiết kiệm ở quy mô này.

1. Tính chi phí Cloudflare

CÔNG THỨC SỬ DỤNG: 10 phút/ngày x 30 ngày = 300 phút/tháng. Mỗi ngày: 10 x 46,63 = 466,3 Neurons. Tỷ lệ dùng quota: 466,3 / 10.000 = 4,66%.

Chỉ số	Kết quả	Ý nghĩa
Audio mỗi ngày	10 phút	Khối lượng người dùng yêu cầu
Audio mỗi tháng	300 phút	Tương đương 5 giờ audio
Neurons mỗi ngày	466,3	Chỉ dùng 4,66% quota miễn phí
Quota miễn phí	10.000/ngày	Reset hằng ngày lúc 00:00 UTC
Giá trị theo list price	$0,153/tháng	Không bị tính nếu không vượt quota ngày
Chi phí Free plan	$0/tháng	Giả định không có tải Workers AI khác
Chi phí Paid plan	$5/tháng	Mức tối thiểu của Workers Paid

Nguồn: Workers AI pricing; Whisper Large V3 Turbo; Workers pricing.

Cloudflare Free có đủ không?

Có, nếu tài khoản chỉ phục vụ người dùng này và tổng tải Workers AI mỗi ngày không vượt 10.000 Neurons. Với 46,63 Neurons/phút, quota tương đương khoảng 214 phút Whisper Large V3 Turbo mỗi ngày; nhu cầu 10 phút/ngày chỉ chiếm khoảng 1/21 quota.

- Workers Free cho phép 100.000 request/ngày; một người dùng thông thường thấp hơn rất nhiều.
- Nếu dùng chung tài khoản cho LLM, TTS hoặc người dùng khác, quota 10.000 Neurons/ngày được chia sẻ và có thể hết sớm hơn.
- Khi vượt quota trên Free plan, inference tiếp theo sẽ lỗi; muốn tiếp tục cần nâng Workers Paid và trả phần vượt mức.

NGÂN SÁCH ĐỀ XUẤT: Giai đoạn thử nghiệm: 0 USD/tháng. Giai đoạn production nhỏ: dự trù 5 USD/tháng để có Workers Paid, dù riêng phần ASR của một user vẫn nằm trong quota AI miễn phí.

2. Tính chi phí Vertex AI custom endpoint

Đây là kịch bản tự đóng gói Whisper hoặc model tương đương vào custom container và triển khai lên Vertex AI Endpoint. Nó không phải Google Speech-to-Text, vốn là một API riêng tính phí theo phút.

ĐƠN GIÁ THAM CHIẾU: n1-standard-4: 0,219 USD/giờ; NVIDIA Tesla T4: 0,402 USD/giờ. Tổng một replica: 0,621 USD/giờ tại us-central1.

2.1. Endpoint luôn sẵn sàng

0,621 x 730 giờ/tháng = 453,33 USD/tháng, tương đương khoảng 11,79 triệu đồng. Chỉ có một user nên gần như toàn bộ GPU sẽ nhàn rỗi.

2.2. Scale-to-zero

Compute thuần cho 5 giờ audio/tháng có thể chỉ khoảng 0,10-0,31 USD nếu GPU xử lý nhanh hơn realtime 10-30 lần. Tuy nhiên con số này không phản ánh cách endpoint tương tác thực tế.

- Vertex cho phép min replica bằng 0, nhưng scale-to-zero có cold start khi model phải tải lại.
- Tài liệu deploy-model ghi min scale-up mặc định là một giờ khi min replica bằng 0.
- Nếu người dùng phát sinh một phiên riêng mỗi ngày, ước tính thực tế tối thiểu khoảng 30 giờ x 0,621 = 18,63 USD/tháng, chưa gồm startup, log, storage và egress.

Kịch bản Vertex	Chi phí compute	Độ trễ	Phù hợp 1 user?
Compute thuần lý thuyết	$0,10-$0,31	Không phản ánh cold start	Không dùng làm ngân sách production
Scale-to-zero, dùng mỗi ngày	Khoảng $18,63+	Cold start cao	Không khuyến nghị cho hội thoại
Một replica luôn chạy	$453,33	Thấp và ổn định	Không kinh tế
Hai replica HA	$906,66	Tốt hơn về HA	Hoàn toàn không phù hợp

Nguồn: Vertex/Agent Platform pricing; Vertex deploy-model scale-to-zero.

Nguồn kỹ thuật

- Cloudflare Workers AI pricing - 10.000 Neurons/ngày miễn phí và đơn giá model
- Cloudflare Whisper Large V3 Turbo - 0,00051 USD/phút audio
- Cloudflare Workers pricing - Free plan và Paid plan tối thiểu 5 USD
- Vertex/Agent Platform pricing - giá n1-standard-4 và T4 theo giờ
- Vertex deploy-model - min replica 0 và scale-to-zero

3. So sánh Cloudflare và Vertex AI

Tiêu chí	Cloudflare Workers AI	Vertex AI custom endpoint
Chi phí 1 user	$0 Free hoặc $5 Paid	$18,63+ scale-to-zero; $453,33 warm
Độ khó	Thấp - khoảng 2/10	Trung bình-cao - khoảng 7/10
Thời gian POC	Khoảng 1-3 ngày	Khoảng 2-4 tuần
Quản lý GPU/CUDA	Không	Phải chọn máy, GPU và container
Cold start	Thấp	Có khi scale-to-zero
Model tùy biến	Hạn chế	Cao; có thể fine-tune model riêng
IAM/VPC GCP	Không nằm trong GCP	Tích hợp tốt với hệ sinh thái GCP
Vận hành	Cloudflare quản lý	Vẫn cần MLOps, benchmark và monitoring

Khi nào nên chọn Vertex dù chi phí cao hơn?

Chất lượng: Model Cloudflare không đạt yêu cầu cho giọng trẻ em hoặc từ vựng chuyên biệt, và model tùy biến chứng minh cải thiện ít nhất 10-15% trên golden set.

Governance: Tổ chức bắt buộc dùng IAM, VPC, audit log, data residency hoặc MLOps trong Google Cloud.

Quy mô: Hệ thống tăng lên hàng nghìn user, GPU có utilization tốt và TCO của Vertex thấp hơn Cloudflare ít nhất 20% sau benchmark thực tế.

Quyết định đề xuất

CHỌN CLOUDFLARE: Với một người dùng nói 10 phút/ngày, Cloudflare rẻ hơn từ khoảng 3,7 lần so với Vertex scale-to-zero thực tế và khoảng 91 lần so với một Vertex replica luôn chạy, nếu so với gói Cloudflare Paid 5 USD. Nếu dùng Cloudflare Free, chênh lệch còn lớn hơn.

1. Bắt đầu bằng Workers Free và theo dõi Neurons/ngày.
2. Nâng Workers Paid khi cần production ổn định hoặc có thêm người dùng/model dùng chung quota.
3. Chỉ tạo Vertex POC ở chế độ shadow khi có mục tiêu chất lượng hoặc governance cụ thể.

4. Giới hạn của ước tính

Báo cáo chỉ tính ASR. Chưa gồm model hội thoại, dịch văn bản, TTS, database, lưu audio, băng thông, thuế và nhân sự. Chi phí Vertex thay đổi theo region, machine type, accelerator, thời gian cold start và cách phân bố request trong ngày.