Triển khai Model AI Cloudflare hay Vertex AI?

部署 AI 模型：选择 Cloudflare 还是 Vertex AI?

Chi phí khi mỗi người dùng nói 10 phút mỗi ngày

按每位用户每天说话 10 分钟估算的成本

Khối lượng mỗi user: 10 phút/ngày/người dùng x 30 ngày = 300 phút/tháng = 5 giờ audio

每位用户的用量：每天 10 分钟 × 30 天 = 每月 300 分钟 = 5 小时音频

Cloudflare: Workers AI + @cf/openai/whisper-large-v3-turbo

Cloudflare：Workers AI + @cf/openai/whisper-large-v3-turbo

Vertex: Custom endpoint: n1-standard-4 + NVIDIA Tesla T4 tại us-central1

Vertex：自定义端点：n1-standard-4 + NVIDIA Tesla T4（us-central1）

Ngày giá: 21/08/2026; quy đổi 26.000 VND/USD; chưa gồm thuế

价格日期：2026 年 8 月 21 日；按 1 美元 = 26,000 越南盾换算；未含税

KẾT LUẬN:

结论：

Từ 1 đến 1.000 user, Cloudflare là lựa chọn mặc định: rẻ hơn, triển khai nhanh và không phải vận hành GPU.

在 1 至 1,000 名用户的范围内，默认推荐 Cloudflare：成本更低、部署更快，并且无需运维 GPU。

Chỉ chuyển sang Vertex AI khi model tùy biến tạo ra lợi ích chất lượng rõ rệt, có yêu cầu IAM/VPC của GCP, hoặc benchmark thực tế chứng minh tổng chi phí thấp hơn.

只有在自定义模型能够显著提升质量、必须使用 GCP 的 IAM/VPC，或实际基准测试证明总成本更低时，才切换到 Vertex AI。

Chi phí theo quy mô
不同用户规模的成本

Giải pháp 方案	User 用户数	Phút/tháng 分钟/月	Tổng USD 合计（美元）	Quy đổi VND 折合越南盾
Cloudflare Workers AI Cloudflare Workers AI 方案	1	300	$0,00	0đ
	100	30.000	$17,09	444 nghìn
	500	150.000	$78,64	2,04 triệu
	1.000	300.000	$155,58	4,05 triệu
	2.000	600.000	$309,46	8,05 triệu
	3.000	900.000	$463,34	12,05 triệu
	5.000	1.500.000	$771,10	20,05 triệu
Vertex AI Vertex AI 方案	1	300	$453,33	11,79 triệu
	100	30.000	$453,33	11,79 triệu
	500	150.000	$453,33	11,79 triệu
	1.000	300.000	$453,33	11,79 triệu
	2.000	600.000	$453,33	11,79 triệu
	3.000	900.000	$453,33	11,79 triệu
	5.000	1.500.000	$453,33	11,79 triệu

1. Cloudflare Workers AI

1. Cloudflare Workers AI

ĐƠN GIÁ:
计价说明:

Mỗi user dùng 466,3 Neurons/ngày.
每位用户每天使用 466.3 Neurons。

Chi phí AI tháng = max(0; 466,3 x số user - 10.000) x 30 x 0,011 / 1.000.
每月 AI 成本 = max(0；466.3 × 用户数 - 10,000) × 30 × 0.011 / 1,000。

Khi vượt quota ngày, cộng tối thiểu 5 USD/tháng cho Workers Paid.
当每日用量超过免费额度时，需要至少支付每月 5 美元的 Workers Paid 套餐费。

Nếu vượt quota Workers Paid, AI được tính riêng ở mức **$0,011/1.000 Neurons**
使用 Workers Paid 后，超出免费额度的 AI 用量按每 1,000 Neurons 0.011 美元另行计费。

User 用户数	Phút/tháng 分钟/月	Tổng USD 合计（美元）	Quy đổi VND 折合越南盾
1	300	$0,00	0đ
100	30.000	$17,09	444 nghìn
500	150.000	$78,64	2,04 triệu
1.000	300.000	$155,58	4,05 triệu
2.000	600.000	$309,46	8,05 triệu
3.000	900.000	$463,34	12,05 triệu
5.000	1.500.000	$771,10	20,05 triệu

2. Vertex AI custom endpoint

2. Vertex AI 自定义端点

ĐƠN GIÁ THAM CHIẾU:
参考单价:

Tổng 1 replica(máy chủ): 0,621 USD/giờ.
1 个副本（服务器）的总成本：每小时 0.621 美元。

1 replica(máy chủ) chạy 24/7 = 453,33 USD/tháng.
1 个副本（服务器）全天候运行 = 每月 453.33 美元。

User 用户数	Audio giờ/tháng 音频小时/月	1 replica(1 máy chủ) 1 个副本（1 台服务器）	2 replica HA(2 máy chủ) 2 个高可用副本（2 台服务器）
1	5	$453,33	$906,66
100	500	$453,33	$906,66
500	2.500	$453,33	$906,66
1.000	5.000	$453,33	$906,66
2.000	10.000	$453,33	$906,66
3.000	15.000	$453,33	$906,66
5.000	25.000	$453,33	$906,66

- **Audio giờ/tháng**: tổng thời lượng audio đầu vào được cộng dồn trong một tháng, không phải GPU chắc chắn phải chạy đúng 5 giờ.
  音频小时/月：一个月内累计的输入音频总时长，并不表示 GPU 一定要运行整整 5 小时。
- **1 replica(1 máy chủ):** là server luôn được bật và model Whisper đã được nạp sẵn vào GPU.
  1 个副本（1 台服务器）：服务器始终开启，Whisper 模型已预先加载到 GPU。
- **2 replica HA(2 máy chủ):** hệ thống sẽ sử dụng 2 máy chủ để hoạt động:
  2 个高可用副本（2 台服务器）：系统将同时使用 2 台服务器运行：
  - 1 máy vẫn phục vụ nếu máy còn lại gặp sự cố.
    如果一台服务器发生故障，另一台仍可继续提供服务。
  - Chia tải khi nhiều người gửi audio đồng thời.
    当多位用户同时发送音频时分担负载。