BÁO CÁO QUYẾT ĐỊNH HẠ TẦNG ASR

Cloudflare hay Vertex AI?

Chi phí khi mỗi người dùng nói 10 phút mỗi ngày

Khối lượng mỗi user: 10 phút/ngày x 30 ngày = 300 phút/tháng = 5 giờ audio
Cloudflare: Workers AI + @cf/openai/whisper-large-v3-turbo
Vertex: Custom endpoint: n1-standard-4 + NVIDIA Tesla T4 tại us-central1
Ngày giá: 21/08/2026; quy đổi 26.000 VND/USD; chưa gồm thuế

KẾT LUẬN: Từ 1 đến 1.000 user, Cloudflare là lựa chọn mặc định: rẻ hơn, triển khai nhanh và không phải vận hành GPU. Chỉ chuyển sang Vertex AI khi model tùy biến tạo ra lợi ích chất lượng rõ rệt, có yêu cầu IAM/VPC của GCP, hoặc benchmark thực tế chứng minh tổng chi phí thấp hơn.

Chi phí theo quy mô

User	Giờ audio/tháng	Cloudflare/tháng	Vertex warm/tháng	Chọn
1	5	$0 Free / $5 Paid	$453,33	Cloudflare
100	500	$17,09	$453,33	Cloudflare
500	2.500	$78,64	$453,33	Cloudflare
1.000	5.000	$155,58	$453,33	Cloudflare

Cloudflare tương ứng khoảng $17,09 cho 100 user; $78,64 cho 500 user; và $155,58 cho 1.000 user. Vertex warm một replica là $453,33/tháng và cần benchmark để biết một T4 có đáp ứng được concurrency hay không.

Ngưỡng quyết định

- Cloudflare Free đủ tối đa khoảng 21 user ở đúng mức 10 phút/ngày, nếu không có tải Workers AI khác.
- Từ 22 user trở lên, cần Workers Paid để inference không bị dừng khi vượt quota Neurons hằng ngày.
- So với một Vertex replica chạy 24/7, điểm hòa vốn lý thuyết của Cloudflare vào khoảng 2.935 user; với hai replica HA là khoảng 5.881 user.

1. Cloudflare Workers AI

CÔNG THỨC: Mỗi user dùng 466,3 Neurons/ngày. Chi phí AI tháng = max(0; 466,3 x số user - 10.000) x 30 x 0,011 / 1.000. Khi vượt quota ngày, cộng tối thiểu 5 USD/tháng cho Workers Paid.

User	Phút/tháng	Tổng USD	Quy đổi VND	Cấu phần
1	300	$0,00	0đ	Free: $0; Paid tùy chọn: $5
100	30.000	$17,09	444 nghìn	AI $12,09 + Paid $5
500	150.000	$78,64	2,04 triệu	AI $73,64 + Paid $5
1.000	300.000	$155,58	4,05 triệu	AI $150,58 + Paid $5

Nguồn: Workers AI pricing; Whisper Large V3 Turbo; Workers pricing.

Vì sao Cloudflare rẻ?

- Workers AI có 10.000 Neurons/ngày miễn phí; Whisper Large V3 Turbo dùng 46,63 Neurons cho mỗi phút audio.
- Đơn giá niêm yết của model là 0,00051 USD/phút audio; Cloudflare vẫn tính backend theo Neurons.
- Không cần giữ GPU ở trạng thái sẵn sàng, nên chi phí tăng gần tuyến tính theo lượng audio thay vì theo giờ máy nhàn rỗi.

Điểm cần kiểm soát

Quota dùng chung: LLM, TTS hoặc dự án khác trong cùng tài khoản có thể ăn vào 10.000 Neurons/ngày.

Free plan dừng inference: Khi vượt quota, các thao tác tiếp theo lỗi cho đến khi quota reset; production từ 22 user nên bật Paid.

Chất lượng: Phải đo WER/CER trên giọng nói thật, đặc biệt với tiếng Việt, giọng trẻ em, tiếng ồn và từ vựng chuyên ngành.

NGÂN SÁCH KHUYẾN NGHỊ: POC: Workers Free. Production 22-1.000 user: Workers Paid + ngân sách AI theo bảng. Đặt cảnh báo Neurons/ngày ở 70%, 85% và 95% để tránh bất ngờ.

2. Vertex AI custom endpoint

Kịch bản này tự đóng gói Whisper hoặc model ASR tương đương vào custom container. Đây không phải Google Cloud Speech-to-Text, vốn là dịch vụ API riêng và có biểu phí khác.

ĐƠN GIÁ THAM CHIẾU: n1-standard-4: 0,219 USD/giờ; NVIDIA Tesla T4: 0,402 USD/giờ. Tổng một replica: 0,621 USD/giờ. Một replica chạy 730 giờ/tháng = 453,33 USD/tháng.

User	Audio giờ/tháng	Scale-to-zero*	1 replica warm	2 replica HA
1	5	$18,63+	$453,33	$906,66
100	500	$18,63-$31,05	$453,33	$906,66
500	2.500	$51,75-$155,25	$453,33	$906,66
1.000	5.000	$103,50-$310,50	$453,33	$906,66

***Nguồn:** Google pricing; Deploy-model / scale-to-zero.*

** Scale-to-zero là ước tính compute với tốc độ xử lý 10-30 lần realtime. Với tải hằng ngày, tài liệu ghi idle scaledown và min scale-up mặc định là 1 giờ khi min replica = 0; vì vậy 1 user được ngân sách hóa tối thiểu khoảng $18,63/tháng. Thực tế còn phụ thuộc cold start và phân bố phiên.*

Chi phí không nằm trong bảng

- Cloud Storage cho model/audio, Artifact Registry, Cloud Logging, egress và thuế.
- Thời gian MLOps: đóng gói container, CUDA/driver, autoscaling, benchmark, giám sát, rollback và vá bảo mật.
- Số replica thực tế: một T4 chưa chắc đáp ứng 1.000 user nếu nhiều phiên đồng thời; phải load test trên traffic profile thật.

Khi Vertex có thể thắng

Nếu traffic được gom thành batch hoặc liên tục đủ lâu, GPU đạt utilization cao và model chạy nhanh hơn realtime, scale-to-zero có thể cạnh tranh về compute. Tuy nhiên với sản phẩm hội thoại, cold start và latency thường quan trọng hơn chi phí thuần.

3. Độ khó và vận hành

Tiêu chí	Cloudflare Workers AI	Vertex AI custom endpoint
Độ khó	Thấp - khoảng 2/10	Trung bình-cao - khoảng 7/10
POC	Khoảng 1-3 ngày	Khoảng 2-4 tuần
GPU/CUDA	Không quản lý	Phải cấu hình và benchmark
Autoscaling	Serverless	Replica, cold start, scale-to-zero
Model tùy biến	Hạn chế theo catalog	Cao; custom container/fine-tune
IAM/VPC GCP	Không native GCP	Tích hợp sâu
Rủi ro chính	Quota và phụ thuộc catalog	Chi phí nhàn rỗi, MLOps, latency

4. Khi nào dừng hoặc chuyển giải pháp?

Dừng Cloudflare-first khi

- WER/CER hoặc độ trễ không đạt SLA sau khi đã thử cấu hình hợp lý, và model custom cải thiện ít nhất 10-15% trên golden set.
- Bắt buộc dữ liệu, IAM, VPC, audit log hoặc quy trình MLOps phải nằm trong Google Cloud.
- Quy mô tiến gần 3.000 user, traffic đủ đều và benchmark cho thấy một T4 đáp ứng tải với TCO thấp hơn Cloudflare ít nhất 20%.

Dừng Vertex warm khi

- Dưới khoảng 3.000 user mà không có lợi ích chất lượng/governance đủ lớn để bù chi phí và công vận hành.
- GPU utilization thấp, cold start làm hỏng trải nghiệm, hoặc cần tăng lên hai replica khiến điểm hòa vốn dịch lên khoảng 5.900 user.
- Sau POC, tổng chi phí sở hữu không thấp hơn Cloudflare ít nhất 20% hoặc SLA không tốt hơn rõ rệt.

LỘ TRÌNH ĐỀ XUẤT: Bắt đầu Cloudflare; đo chi phí thực, WER/CER và p95 latency. Ở 500-1.000 user, chỉ chạy Vertex ở chế độ shadow nếu có mục tiêu chất lượng hoặc governance. Xem xét Vertex làm primary quanh 3.000+ user sau load test, không dựa riêng vào phép chia giá GPU.

Nguồn và giới hạn

- Cloudflare Workers AI pricing - quota Neurons và đơn giá
- Cloudflare Whisper Large V3 Turbo - đơn giá/phút audio
- Cloudflare Workers pricing - Paid tối thiểu 5 USD

- Google pricing - n1-standard-4 và T4
- Vertex deploy-model - scale-to-zero và thời gian mặc định

Chưa gồm LLM hội thoại, TTS, database, lưu audio, băng thông, thuế và nhân sự. Giá và tính năng có thể thay đổi; cần kiểm tra lại trước khi ký ngân sách.