Cloudflare hay Vertex AI?

Chi phí khi mỗi người dùng nói 10 phút mỗi ngày

Khối lượng mỗi user: 10 phút/ngày/người dùng x 30 ngày = 300 phút/tháng = 5 giờ audio
Cloudflare: Workers AI + @cf/openai/whisper-large-v3-turbo
Vertex: Custom endpoint: n1-standard-4 + NVIDIA Tesla T4 tại us-central1
Ngày giá: 21/08/2026; quy đổi 26.000 VND/USD; chưa gồm thuế

KẾT LUẬN:

Từ 1 đến 1.000 user, Cloudflare là lựa chọn mặc định: rẻ hơn, triển khai nhanh và không phải vận hành GPU.

Chỉ chuyển sang Vertex AI khi model tùy biến tạo ra lợi ích chất lượng rõ rệt, có yêu cầu IAM/VPC của GCP, hoặc benchmark thực tế chứng minh tổng chi phí thấp hơn.

Chi phí theo quy mô

Giải pháp	User	Phút/tháng	Tổng USD	Quy đổi VND
Cloudflare Workers AI	1	300	$0,00	0đ
	100	30.000	$17,09	444 nghìn
	500	150.000	$78,64	2,04 triệu
	1.000	300.000	$155,58	4,05 triệu
	2.000	600.000	$309,46	8,05 triệu
	3.000	900.000	$463,34	12,05 triệu
	5.000	1.500.000	$771,10	20,05 triệu
Vertex AI	1	300	$453,33	11,79 triệu
	100	30.000	$453,33	11,79 triệu
	500	150.000	$453,33	11,79 triệu
	1.000	300.000	$453,33	11,79 triệu
	2.000	600.000	$453,33	11,79 triệu
	3.000	900.000	$453,33	11,79 triệu
	5.000	1.500.000	$453,33	11,79 triệu

1. Cloudflare Workers AI

ĐƠN GIÁ:

Mỗi user dùng 466,3 Neurons/ngày.

Chi phí AI tháng = max(0; 466,3 x số user - 10.000) x 30 x 0,011 / 1.000.

Khi vượt quota ngày, cộng tối thiểu 5 USD/tháng cho Workers Paid.

Nếu vượt quota Workers Paid, AI được tính riêng ở mức **$0,011/1.000 Neurons**

User	Phút/tháng	Tổng USD	Quy đổi VND
1	300	$0,00	0đ
100	30.000	$17,09	444 nghìn
500	150.000	$78,64	2,04 triệu
1.000	300.000	$155,58	4,05 triệu
2.000	600.000	$309,46	8,05 triệu
3.000	900.000	$463,34	12,05 triệu
5.000	1.500.000	$771,10	20,05 triệu

2. Vertex AI custom endpoint

ĐƠN GIÁ THAM CHIẾU:

Tổng 1 replica(máy chủ): 0,621 USD/giờ.

1 replica(máy chủ) chạy 24/7 = 453,33 USD/tháng.

User	Audio giờ/tháng	1 replica(1 máy chủ)	2 replica HA(2 máy chủ)
1	5	$453,33	$906,66
100	500	$453,33	$906,66
500	2.500	$453,33	$906,66
1.000	5.000	$453,33	$906,66
2.000	10.000	$453,33	$906,66
3.000	15.000	$453,33	$906,66
5.000	25.000	$453,33	$906,66

- ***Audio giờ/tháng:*** *tổng thời lượng audio đầu vào được cộng dồn trong một tháng****, không phải GPU chắc chắn phải chạy đúng 5 giờ.***
- **1 replica(1 máy chủ): nghĩa là server luôn được bật và model Whisper đã được nạp sẵn vào GPU.**
- ***2 replica HA(2 máy chủ): hệ thống sẽ sử dụng 2 máy chủ để hoạt động:***
  - **Một máy vẫn phục vụ nếu máy còn lại gặp sự cố.**
  - **Chia tải khi nhiều người gửi audio đồng thời.**